中国科学院大学
University of Chinese Academy of Sciences

博士学位论文

语音到语音生成模型结构研究

作者姓名：房庆凯

指导教师：冯洋 研究员

中国科学院计算技术研究所

学位类别：工学博士

学科专业：计算机应用技术

培养单位：中国科学院计算技术研究所

2026 年 6 月

Research on Model Architectures for Speech-to-Speech Generation

A dissertation submitted to

University of Chinese Academy of Sciences

in partial fulfillment of the requirement

for the degree of

Doctor of Philosophy

in Computer Applied Technology

By

FANG Qingkai

Supervisor: Professor FENG Yang

Institute of Computing Technology, Chinese Academy of Sciences

June, 2026

中国科学院大学
学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究工作所取得的成果。承诺除文中已经注明引用的内容外，本论文不包含任何其他个人或集体享有著作权的研究成果，未在以往任何学位申请中全部或部分提交。对本论文所涉及的研究工作做出贡献的其他个人或集体，均已在文中以明确方式标明或致谢。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日　　期：

中国科学院大学
学位论文授权使用声明

本人完全了解并同意遵守中国科学院大学有关收集、保存和使用学位论文的规定，即中国科学院大学有权按照学术研究公开原则和保护知识产权的原则，保留并向国家指定或中国科学院指定机构送交学位论文的电子版和印刷版文件，且电子版与印刷版内容应完全相同，允许该论文被检索、查阅和借阅，公布本学位论文的全部或部分内容，可以采用扫描、影印、缩印等复制手段以及其他法律许可的方式保存、汇编本学位论文。

涉密及延迟公开的学位论文在解密或延迟期后适用本声明。

作者签名：　　导师签名：

日　　期：　　日　　期：

摘　要

关键词：关键词 1，关键词 2，关键词 3

Abstract

Key Words: Keyword1, Keyword2, Keyword3

目 录

第 1 章 绪论 ····· 1
第 2 章 基于有向无环图的语音到语音翻译模型 ····· 3
2.1 引言 ····· 3
2.2 方法介绍 ····· 4
2.2.1 相关技术 ····· 4
2.2.2 模型架构 ····· 6
2.2.3 期望路径训练 ····· 6
2.2.4 解码策略 ····· 8
2.3 实验结果与分析 ····· 9
2.3.1 实验设置 ····· 9
2.3.2 主要结果 ····· 11
2.3.3 分析实验 ····· 12
2.4 本章小结 ····· 16
第 3 章 ComSpeech ····· 19
第 4 章 LLaMA-Omni ····· 21
第 5 章 LLaMA-Omni 2 ····· 23
第 6 章 总结与展望 ····· 25
参考文献 ····· 27
致谢 ····· 31
作者简历及攻读学位期间发表的学术论文与其他相关学术成果 · 33

图目录

图 2-1 DASpeech 模型架构 ····· 6
图 2-2 不同源语音长度下的翻译延迟对比 ····· 13
图 2-3 翻译质量与解码速度的权衡 ····· 14
图 2-4 不同批量大小下的解码加速比与翻译质量 ····· 14
图 2-5 不同图尺寸下 S2TT 模型的翻译质量 ····· 15
图 2-6 不同图尺寸下 DASpeech 的翻译质量 ····· 15

表目录

表 2-1 CVSS 法语到英语数据集上的语音翻译结果 ····· 11
表 2-2 CVSS-C 多语言数据集上的语音翻译结果 ····· 12
表 2-3 期望路径训练与最优路径训练的对比 ····· 13
表 2-4 各模型的说话人相似度对比 ····· 16

符号列表

第 1 章　绪论

第 2 章　基于有向无环图的语音到语音翻译模型

2.1　引言

语音到语音翻译（Speech-to-Speech Translation, S2ST）旨在将源语言的语音直接翻译为目标语言的语音，是语音到语音生成中最基础和最典型的任务之一，在国际会议、跨国交流、影视译制等领域具有广阔的应用前景。在语音到语音翻译中，模型需要同时处理语言转换和语音生成两个层面的问题，因此对模型的建模能力提出了很高的要求。传统的语音到语音翻译系统通常由自动语音识别（Automatic Speech Recognition, ASR）、机器翻译（Machine Translation, MT）和语音合成（Text-to-Speech, TTS）三个独立模块级联而成。然而，这种级联方式存在诸多问题：一方面，各模块之间的错误会逐级传播和累积；另一方面，级联系统无法保留源语音中的副语言信息（如说话人音色），且多模块串行处理导致解码延迟较高。为此，研究者们提出了端到端的语音到语音翻译方法，通过单一模型实现从源语音到目标语音的直接转换，不仅可以避免级联系统中的错误传播问题，还具有降低解码延迟和保留说话人音色的潜力。

尽管端到端语音到语音翻译具有诸多优势，但在实践中训练高质量的端到端模型仍面临巨大挑战。核心难点在于目标语音服从复杂的多峰分布（Multi-modality Distribution）。这种多峰性来源于两个方面：其一是语言多样性，即同一源语句可能对应多种合理的翻译结果；其二是声学多样性，即同一文本内容在语音层面也存在时长、音高、能量、说话人特征等多方面的变化。早期的端到端语音到语音翻译模型采用一阶段解码架构，如 S2UT[1] 和 Translatotron[2]，直接从源语音生成目标语音的离散单元或梅尔谱（Mel-spectrogram）。由于一阶段模型需要同时建模语言多样性和声学多样性，学习难度较大，翻译质量受限。为此，研究者们进一步提出了二阶段解码架构，如 UnitY[3] 和 Translatotron 2[4]，先生成目标文本（如音素序列），再基于文本的隐状态生成目标语音。二阶段架构将生成过程分解为内容翻译和语音合成两个步骤，有效降低了建模目标语音复杂分布的难度，在翻译质量上取得了显著提升。

然而，上述模型均采用自回归解码器，按从左到右的顺序逐步生成目标序列。由于语音序列通常较长，自回归解码的计算开销很大，导致解码延迟较高，特别是二阶段模型需要进行两次自回归解码，延迟问题更为突出。为了降低解码延迟，研究者们开始探索非自回归的语音到语音翻译方法。例如，TranSpeech[5] 通过并行生成目标语音的离散单元来加速解码，DiffS2UT[6] 则采用扩散模型进行非自回归语音生成。虽然这些非自回归模型在解码速度上取得了显著提升，但由于非自回归模型固有的条件独立假设，在面对目标语音的多峰分布时建模能力受限，导致翻译质量与自回归模型仍有明显差距。这种建模能力的不足在非自回归序列生成领域被称为多峰性问题（Multi-modality Problem）[7]。因此，如何在非自回归框架下有效建模目标语音的多峰分布，在保持高翻译质量的同时大幅

提升解码效率，是本章需要解决的关键问题。

针对上述问题，本章提出了 DASpeech，一个非自回归的二阶段端到端语音到语音翻译模型，在取得与自回归模型相当翻译质量的同时大幅提升了解码速度。在模型设计上，DASpeech 包含语音编码器、非自回归语言解码器和非自回归声学解码器三个组件。其中，语言解码器采用有向无环图 Transformer（Directed Acyclic Transformer, DA-Transformer）[8] 的解码器结构，将解码器最后一层的隐状态组织为一个有向无环图（Directed Acyclic Graph, DAG），通过 DAG 中的不同路径来建模不同的翻译候选，有效缓解非自回归翻译中的语言多峰性问题。声学解码器采用 FastSpeech 2[9] 的结构，通过显式建模时长、音高和能量等变化信息来缓解声学多峰性问题，从而实现高质量的非自回归语音合成。为了实现整个模型的端到端训练，本章提出了期望路径训练算法（Expect-Path Training），采用隐马尔科夫模型中的前向-后向算法计算目标序列每个位置对应的期望隐状态，将其作为声学解码器的输入。在推理阶段，首先在 DAG 中选择一条概率最大的路径，并将该路径上的隐状态输入声学解码器，通过两次并行解码生成目标语音。

本章在 CVSS 法语到英语数据集上进行了实验验证。实验结果表明：（1）DASpeech 在翻译质量上明显超越 S2UT 和 Translatotron 等一阶段自回归模型，与二阶段自回归模型 Translatotron 2 的性能持平甚至更优，同时解码速度相较于 S2UT 取得了最高 18.53 倍的加速；（2）与先前的非自回归模型 TranSpeech 相比，DASpeech 无需知识蒸馏和迭代解码，在翻译质量和解码速度两方面均取得了显著优势；（3）DASpeech 在包含多说话人目标语音的数据集上展现出音色保持能力，证明了其在处理复杂声学条件下的潜力。

2.2 方法介绍

本节介绍 DASpeech 的模型架构和训练方法。形式化地，源语音序列表示为 $X = (x_1, ..., x_N)$，其中 N 为源语音的帧数；目标音素序列表示为 $Y = (y_1, ..., y_M)$；目标梅尔谱序列表示为 $S = (s_1, ..., s_T)$。DASpeech 首先通过语音到文本翻译（Speech-to-Text Translation, S2TT）的 DA-Transformer 从 X 生成 Y，随后基于 DA-Transformer 最后一层的隐状态，使用 FastSpeech 2 风格的解码器生成 S。

2.2.1 相关技术

2.2.1.1 DA-Transformer

有向无环图 Transformer（DA-Transformer）[8,10] 是一种面向非自回归机器翻译（Non-Autoregressive Translation, NAT）的模型，其在不依赖知识蒸馏的条件下取得了与自回归 Transformer[11] 相当的翻译性能。DA-Transformer 由一个 Transformer 编码器和一个非自回归解码器组成。解码器最后一层的隐状态被组织为一个有向无环图（DAG），其中隐状态对应图中的结点，编号小的结点到编号大的结点之间有一条有向边相连。DA-Transformer 通过 DAG 中的不同路径同时编码多种翻译候选，有效缓解了非自回归翻译中的语言多峰性问题。

形式化地，对于源端输入序列 $X = (x_1, ..., x_N)$ 和目标序列 $Y = (y_1, ..., y_M)$，编码器以 X 为输入，解码器以可学习的位置编码 $\mathbf{G} = (\mathbf{g}_1, ..., \mathbf{g}_L)$ 为输入，其中 $L = \lambda \cdot N$ 为图的大小，λ 是超参数。DA-Transformer 通过边际化 DAG 中所有可能的路径来建模翻译概率：

$$P_\theta(Y|X) = \sum_{A \in \Gamma} P_\theta(Y|A, X) P_\theta(A|X), \tag{2-1}$$

其中，$A = (a_1, ..., a_M)$ 表示一条路径，满足 $1 = a_1 < \cdots < a_M = L$，$\Gamma$ 是包含所有长度为 M 的路径的集合。路径 A 的概率定义为：

$$P_\theta(A|X) = \prod_{i=1}^{M-1} P_\theta(a_{i+1}|a_i, X) = \prod_{i=1}^{M-1} \mathbf{E}_{a_i, a_{i+1}}, \tag{2-2}$$

其中，$\mathbf{E} \in \mathbb{R}^{L \times L}$ 是转移概率矩阵，添加下三角掩码以保证只能从编号小的结点向编号大的结点转移。当路径 A 确定后，所有目标词根据路径上的结点并行预测：

$$P_\theta(Y|A, X) = \prod_{i=1}^{M} P_\theta(y_i|a_i, X) = \prod_{i=1}^{M} \mathbf{P}_{a_i, y_i}, \tag{2-3}$$

其中，$\mathbf{P} \in \mathbb{R}^{L \times |\mathbb{V}|}$ 是预测概率矩阵，$\mathbb{V}$ 为目标语言词表。DA-Transformer 的训练目标为最小化负对数似然：

$$\mathcal{L}_{\text{DAT}} = -\log P_\theta(Y|X) = -\log \sum_{A \in \Gamma} P_\theta(Y|A, X) P_\theta(A|X), \tag{2-4}$$

此处的求和可通过动态规划高效求解。

2.2.1.2　FastSpeech 2

FastSpeech 2[9] 是一种非自回归语音合成模型，能够从输入的音素序列并行生成语音的梅尔谱。它由三个堆叠的模块组成：编码器、方差适配器（Variance Adaptor）和梅尔谱解码器。编码器和梅尔谱解码器包含若干个前馈 Transformer 块，每个块由一个自注意力层和一个一维卷积层组成。方差适配器包含三个方差预测器，分别为时长预测器（Duration Predictor）、音高预测器（Pitch Predictor）和能量预测器（Energy Predictor），用于弥合输入音素序列和输出梅尔谱之间的信息差距。在训练过程中，使用真实的时长、音高和能量来训练这些方差预测器，并将其作为条件输入以生成梅尔谱；在推理过程中，则使用这些预测器的预测值。变化信息的显式引入极大地缓解了声学多峰性问题，从而提高了语音质量。FastSpeech 2 的训练目标由以下四项组成：

$$\mathcal{L}_{\text{TTS}} = \mathcal{L}_{\text{L1}} + \mathcal{L}_{\text{dur}} + \mathcal{L}_{\text{pitch}} + \mathcal{L}_{\text{energy}}, \tag{2-5}$$

其中 $\mathcal{L}_{\text{L1}}$ 衡量预测梅尔谱与真实梅尔谱之间的 L1 距离，$\mathcal{L}_{\text{dur}}$、$\mathcal{L}_{\text{pitch}}$ 和 $\mathcal{L}_{\text{energy}}$ 分别计算时长、音高和能量的预测值与真实值之间的均方误差（MSE）。

2.2.2 模型架构

如图2-1所示，DASpeech 包含三个部分：语音编码器、非自回归语言解码器和非自回归声学解码器。以下分别介绍各组件的详细设计。

语音编码器 由于 DASpeech 以语音特征作为输入，本章将 DA-Transformer 原始的 Transformer 编码器替换为语音编码器。语音编码器首先包含一个基于 CNN 的下采样模块（Subsampler），由两个一维卷积层组成，将输入序列长度缩减为原来的四分之一。随后是若干个 Conformer[12] 块，Conformer 结合了多头注意力机制和卷积层的优势，能够同时捕捉全局特征和局部特征。多头注意力模块采用相对位置编码[13]。

非自回归语言解码器 语言解码器与 DA-Transformer 的解码器结构相同，用于从源语音并行生成目标音素序列。解码器的每一层包含自注意力层、交叉注意力层和前馈层。解码器以可学习的位置编码作为输入，最后一层的隐状态被组织为 DAG 来建模翻译。

非自回归声学解码器 声学解码器采用 FastSpeech 2 的设计，从 DA-Transformer 最后一层的隐状态并行生成目标梅尔谱。其模型结构与前文介绍的 FastSpeech 2 相同，但移除了输入音素的嵌入矩阵，因为输入已从音素序列变为隐状态序列。在两个解码器之间插入一个两层前馈网络（FFN），用于将语言解码器的输出维度转换到声学解码器的输入维度。

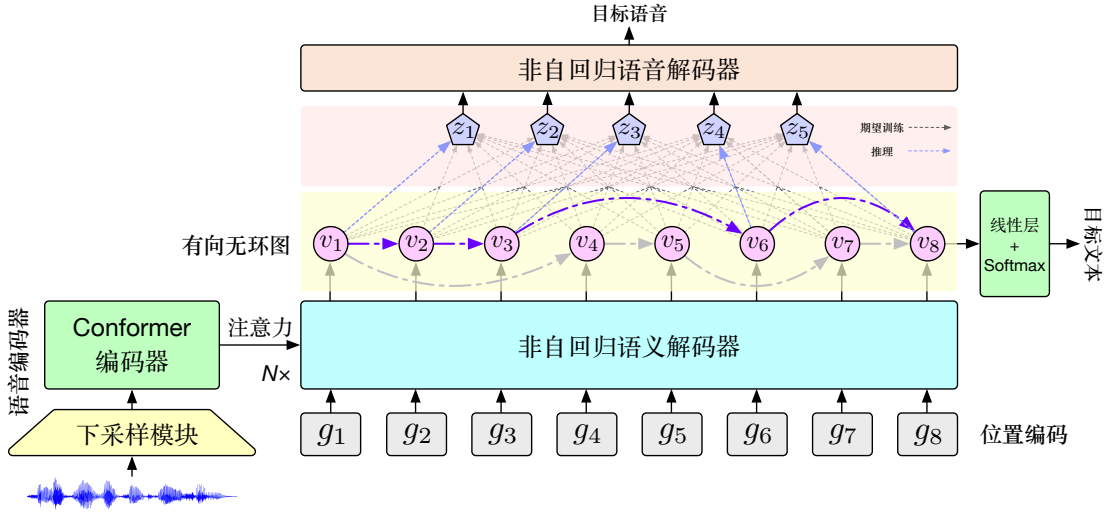

图 2-1 DASpeech 模型架构

Figure 2-1 Architecture of DASpeech

2.2.3 期望路径训练

DASpeech 可以利用预训练的 S2TT DA-Transformer 模型初始化语音编码器和语言解码器，利用预训练的 FastSpeech 2 模型初始化声学解码器，然后端到端微调整个模型。这种预训练-微调范式简化了模型训练过程，并允许模型利用额外的语音到文本翻译数据和语音合成数据。然而，端到端微调面临一个核心挑战

——语言解码器输出与声学解码器输入之间的长度不匹配问题。具体来说，语言解码器的隐状态序列长度为 $L = \lambda \cdot N$，包含 DAG 中所有结点的表示，而声学解码器要求的输入序列长度为 M，即目标音素序列的长度。因此，需要确定如何从语言解码器最后一层的隐状态 $\mathbf{V} = (\mathbf{v}_1, ..., \mathbf{v}_L)$ 中获得声学解码器的输入序列 $\mathbf{Z} = (\mathbf{z}_1, ..., \mathbf{z}_M)$。

直观地讲，输入声学解码器的第 i 个元素 $\mathbf{z}_i$ 应当是负责生成 y_i 的结点的隐状态表示。然而，DAG 中存在多条可能的路径，对于每个 y_i，可能有多个不同的结点负责生成它。为了在训练时同时考虑所有路径，本章将 $\mathbf{z}_i$ 定义为后验分布 $P_\theta(a_i|X, Y)$ 下的期望隐状态：

$$\mathbf{z}_i = \sum_{j=1}^{L} P_\theta(a_i = j|X, Y) \cdot \mathbf{v}_j, \tag{2-6}$$

其中 $P_\theta(a_i = j|X, Y)$ 表示路径 A 上第 i 个结点为结点 j 的概率，即结点 j 负责生成 y_i 的概率。具体地，$P_\theta(a_i = j|X, Y)$ 的计算方式如下：

$$\begin{aligned} P_\theta(a_i = j|X, Y) &= \sum_{A \in \Gamma} \mathbb{1}(a_i = j) \cdot P_\theta(A|X, Y) \\ &= \frac{\sum_{A \in \Gamma} \mathbb{1}(a_i = j) \cdot P_\theta(Y, A|X)}{\sum_{A \in \Gamma} P_\theta(Y, A|X)}, \end{aligned} \tag{2-7}$$

其中 $\mathbb{1}(a_i = j)$ 是指示函数，用于判断路径 A 的第 i 个顶点是否为顶点 j。

为了高效计算公式 (2-7) 中的分子和分母，本章采用前向-后向算法[14]，即两次动态规划过程。

前向算法　前向概率定义为 $\alpha_i(j) = P_\theta(y_1, ..., y_i, a_i = j|X)$，表示生成部分目标序列 $(y_1, ..., y_i)$ 并在第 i 步结束于顶点 j 的概率。根据定义，初始条件为 $\alpha_1(1) = \mathbf{P}_{1,y_1}$ 以及 $\alpha_1(1 < j \leq L) = 0$。由马尔可夫性质，可按顺序从前一步 $\alpha_{i-1}(\cdot)$ 递推计算 $\alpha_i(\cdot)$：

$$\alpha_i(j) = \mathbf{P}_{j,y_i} \sum_{k=1}^{j-1} \alpha_{i-1}(k) \cdot \mathbf{E}_{k,j}. \tag{2-8}$$

后向算法　后向概率定义为 $\beta_i(j) = P_\theta(y_{i+1}, ..., y_M|a_i = j, X)$，表示从第 i 步起始于顶点 j 并生成目标序列剩余部分 $(y_{i+1}, ..., y_M)$ 的概率。初始条件为 $\beta_M(L) = 1$ 以及 $\beta_M(1 \leq j < L) = 0$。类似于前向算法，可从下一步 $\beta_{i+1}(\cdot)$ 递推计算 $\beta_i(\cdot)$：

$$\beta_i(j) = \sum_{k=j+1}^{L} \mathbf{E}_{j,k} \cdot \beta_{i+1}(k) \cdot \mathbf{P}_{k,y_{i+1}}. \tag{2-9}$$

回顾公式 (2-7)，分母为所有有效路径概率之和，等于 $\alpha_M(L)$；分子为所有满足 $a_i = j$ 的路径概率之和，等于 $\alpha_i(j) \cdot \beta_i(j)$。因此，公式 (2-6) 可以计算为：

$$\mathbf{z}_i = \sum_{j=1}^{L} P_\theta(a_i = j|X, Y) \cdot \mathbf{v}_j = \sum_{j=1}^{L} \frac{\alpha_i(j) \cdot \beta_i(j)}{\alpha_M(L)} \cdot \mathbf{v}_j. \tag{2-10}$$

前向-后向算法的时间复杂度为 $\mathcal{O}(ML^2)$。

除期望路径训练外，本章也实验了一种更简单的训练方法——最优路径训练（Best-Path Training），其核心思想是通过 Viterbi 算法[15] 选择概率最大的路径 $\hat{A} = \arg\max_{A\in\Gamma} P_\theta(Y, A|X)$，将该路径上的隐状态 $\mathbf{z}_i = \mathbf{v}_{\hat{a}_i}$ 作为声学解码器的输入。具体来说，$\delta_i(j)$ 表示以顶点 j 结束的最优部分路径 $(\hat{a}_1, ..., \hat{a}_i)$ 生成 $(y_1, ..., y_i)$ 的概率。初始条件为 $\delta_1(1) = \mathbf{P}_{1,y_1}$，$\delta_1(1 < j \leq L) = 0$。对于 $i > 1$，可递推计算：

$$\delta_i(j) = \max_{k<j}(\delta_{i-1}(k) \cdot \mathbf{E}_{k,j} \cdot \mathbf{P}_{j,y_i}), \tag{2-11}$$

经过 M 步迭代后，通过从 $\hat{a}_M = L$ 回溯即可得到最优路径。最优路径训练虽然简单直接，但仅有最优路径上的隐状态参与 TTS 训练，可能导致其余隐状态训练不充分。相比之下，期望路径训练让所有隐状态都参与 TTS 训练，能够取得更好的性能。

训练目标 DASpeech 的总体训练目标为：

$$\mathcal{L}_{\text{DASpeech}} = \mathcal{L}_{\text{DAT}} + \mu \cdot \mathcal{L}_{\text{TTS}}, \tag{2-12}$$

其中 μ 为语音合成损失的权重系数，$\mathcal{L}_{\text{DAT}}$ 和 $\mathcal{L}_{\text{TTS}}$ 分别如公式 (2-4) 和公式 (2-5) 所定义。

训练流程 DASpeech 采用预训练-微调范式：

(1) **S2TT 预训练**：语音编码器和语言解码器在语音到音素翻译任务上进行预训练。在多语言场景下，由于低资源语言数据有限，从源语音到目标音素的映射较难学习，为此本章采用由粗到细的预训练策略——先在语音到子词翻译任务上预训练，再在语音到音素翻译任务上预训练。

(2) **TTS 预训练**：声学解码器在语音合成任务上进行预训练。

(3) **端到端微调**：使用上述预训练参数初始化后，整个模型在语音到语音翻译数据上进行端到端微调。

此外，训练期间还引入了 Glancing 策略[16] 以缓解多峰性问题。该策略首先根据最优路径将目标词分配到对应的顶点，然后遮蔽部分词，让模型学习在部分信息缺失的情况下进行预测。遮蔽率 τ 在预训练阶段从 0.5 线性退火至 0.1，在微调阶段固定为 0.1。

2.2.4 解码策略

在推理阶段，DASpeech 执行两次并行解码。首先，使用 DA-Transformer 的解码策略在 DAG 中找到最可能的路径 A^*；然后，将该路径上的最后一层隐状态输入声学解码器，并行生成目标梅尔谱；最后，预测的梅尔谱通过预训练的 HiFi-GAN 声码器[17] 转换为语音波形。由于 DAG 解码和 TTS 解码均为完全并行，因此 DASpeech 在解码效率上相比依赖两次自回归解码的模型取得了显著提升。本章采用以下两种 DA-Transformer 解码策略：

Lookahead 解码　Lookahead 以贪心方式逐步选择 a_i 和 y_i。在每个解码步骤中，同时考虑转移概率和预测概率：

$$a_i^*, y_i^* = \arg\max_{a_i, y_i} P_\theta(y_i|a_i, X) P_\theta(a_i|a_{i-1}, X). \tag{2-13}$$

Joint-Viterbi 解码　Joint-Viterbi 解码[18] 通过 Viterbi 解码[15] 找到翻译和解码路径的全局联合最优解：

$$A^*, Y^* = \arg\max_{A,Y} P_\theta(Y, A|X). \tag{2-14}$$

解码完成后，先确定目标长度 M，然后从 $a_M^* = L$ 回溯得到最优路径。Joint-Viterbi 解码在翻译质量上通常优于 Lookahead，但解码速度略慢。

2.3　实验结果与分析

2.3.1　实验设置

2.3.1.1　数据集

本章在 CVSS[19] 数据集上进行实验。CVSS 是一个大规模的语音到语音翻译语料库，包含从 21 种语言到英语的语音翻译对。该数据集由 CoVoST 2[20] 语音到文本翻译语料库扩展而来，利用先进的 TTS 模型将目标文本合成为语音。CVSS 包含两个版本：CVSS-C 和 CVSS-T。CVSS-C 中所有目标语音均为同一说话人的声音；CVSS-T 中目标语音克隆了对应源语音说话人的声音。

本章在 CVSS-C 和 CVSS-T 的法语到英语（Fr→En）数据集上进行主实验，其训练集、验证集、测试集分别包含 207,364、14,759、14,759 条平行数据。此外，本章还进行了多语言实验，将 CVSS-C 中所有 21 个语言方向的数据合并，训练一个从多种源语言翻译到英语的统一 S2ST 模型。

2.3.1.2　模型配置

DASpeech 各组件的具体配置如下。语音编码器由 12 层 Conformer 组成，其隐层维度为 256，注意力头数为 4，前馈网络维度为 2,048。语言解码器由 4 层 Transformer 解码器组成，其隐层维度为 512，注意力头数为 8，前馈网络维度为 2,048。声学解码器由 8 层前馈 Transformer 块组成，其隐层维度为 256，注意力头数为 4，前馈网络维度为 1,024。声学解码器中的三个方差预测器各包含两层一维卷积，隐层维度为 256，卷积核大小为 3，Dropout 率为 0.5。两个解码器之间插入一个两层前馈网络，将维度从 512 转换为 256。模型总参数量约为 93M。正则化方面，Dropout 设置为 0.1，权重衰减为 0.01，不使用标签平滑。使用在 VCTK 数据集[21] 上预训练的 HiFi-GAN 声码器将梅尔谱转换为波形。

2.3.1.3　训练细节

在 S2TT 预训练阶段，语音编码器和语言解码器在语音到音素翻译任务上训练 100,000 步，每批 320,000 音频帧，学习率在 10,000 步内预热至 5×10^{-4}。在

TTS 预训练阶段，声学解码器在语音合成任务上训练 100,000 步，批大小 512，学习率在 4,000 步内预热至 5×10^{-4}。在端到端微调阶段，整个模型训练 50,000 步，每批 320,000 音频帧，学习率在 4,000 步内预热至 1×10^{-3}。预训练和微调均使用 Adam 优化器[22]。TTS 损失权重 μ 在 $\{1.0, 2.0, 5.0, 10.0\}$ 中实验后选定为 $\mu = 5.0$。

在多语言实验中，本章采用由粗到细的预训练策略。首先使用 SentencePiece 工具学习大小为 6,000 的子词词表，在语音到子词翻译任务上进行预训练，随后切换为语音到音素翻译任务继续预训练。第二阶段预训练时，解码器的嵌入矩阵和输出投影矩阵被替换并从头训练。

所有模型均基于 fairseq[23] 工具包实现，使用 4 块 NVIDIA RTX 3090 GPU 进行训练。微调阶段每 2,000 步保存检查点，最终平均最后 5 个检查点用于评估。

2.3.1.4 评价指标

翻译质量 本章采用 ASR-BLEU 指标评估翻译质量。该方法首先使用预训练的 ASR 模型将翻译后的语音转录为文本，然后使用 SacreBLEU[24] 工具计算转录文本与参考文本之间的 BLEU 分数[25]。统计显著性通过配对自助采样法计算。

解码速度 解码速度以测试集上的解码加速比衡量，在单块 RTX 3090 GPU 上以批大小 1 测试，以 S2UT 的解码速度作为基准。

说话人相似度 本章通过说话人相似度衡量模型的音色保持能力，使用预训练的 d-vector 说话人验证模型[26] 分别提取源语音和生成语音的说话人嵌入，计算两者之间的余弦相似度作为说话人相似度。

2.3.1.5 基线系统

本章与以下基线系统进行对比：

- **S2UT**[1]：一阶段自回归 S2ST 模型，使用预训练 mHuBERT 模型提取目标语音的离散单元作为生成目标，并引入预测目标音素的辅助任务帮助模型收敛。
- **Translatotron**[2]：一阶段自回归 S2ST 模型，以目标梅尔谱作为生成目标，声学解码器的压缩因子为 5。
- **UnitY**[27]：二阶段自回归 S2ST 模型，先生成目标音素再生成离散单元。
- **Translatotron 2**[4]：二阶段自回归 S2ST 模型，先生成目标音素再生成梅尔谱。本章使用 Transformer 替换原始的 LSTM，并在两个解码器之间引入额外的编码器。
- **TranSpeech**[5]：非自回归 S2ST 模型，并行生成目标离散单元，引入双边扰动来解耦离散单元中的声学变化信息。
- **S2T + FastSpeech 2**：由自回归语音到文本翻译模型和 FastSpeech 2 组成的级联系统。
- **DAT + FastSpeech 2**：由 S2TT DA-Transformer 和 FastSpeech 2 组成的级

联系统。

表 2-1　CVSS 法语到英语数据集上的语音翻译结果

Table 2-1　Speech translation results on CVSS Fr→En datasets

模型	解码方式	参数量	ASR-BLEU		加速比
			CVSS-C	CVSS-T	
一阶段自回归模型					
S2UT [1]	Beam=10	73M	22.23	22.28	1.00×
Translatotron [2]	自回归	79M	16.96	11.25	2.32×
二阶段自回归模型					
UnitY [3]	Beam=(10, 1)	64M	24.09	24.29	1.43×
Translatotron 2 [4]	Beam=10	87M	**25.21**	24.39	1.42×
非自回归模型					
TranSpeech♣ [5]	迭代 5 次	67M	17.24	/	11.04×
+ b=15 + NPD†,♣	迭代 15 次	67M	18.39	/	2.53×
TranSpeech♠ [5]	迭代 5 次	67M	16.38	16.49	12.45×
+ b=15 + NPD†,♠	迭代 15 次	67M	19.05	18.60	3.35×
DASpeech ($\lambda = 0.5$)	Lookahead	93M	24.71**	24.45**	**18.53**×
DASpeech ($\lambda = 0.5$)	Joint-Viterbi	93M	**25.03****	**25.26****	16.29×
DASpeech ($\lambda = 1.0$)	Lookahead	93M	24.41**	24.17**	18.45×
DASpeech ($\lambda = 1.0$)	Joint-Viterbi	93M	24.80**	24.48**	15.65×
级联系统					
S2T + FastSpeech 2	Beam=10	49M+41M	24.71	24.49	/
DAT + FastSpeech 2 ($\lambda = 0.5$)	Lookahead	51M+41M	22.19	22.10	/
DAT + FastSpeech 2 ($\lambda = 0.5$)	Joint-Viterbi	51M+41M	22.80	22.75	/
DAT + FastSpeech 2 ($\lambda = 1.0$)	Lookahead	51M+41M	22.68	22.57	/
DAT + FastSpeech 2 ($\lambda = 1.0$)	Joint-Viterbi	51M+41M	23.20	23.15	/

♣ 引用自 Huang 等 [5]，♠ 本章复现，† 目标长度束 = 15 + 并行噪声解码，** 相较于 S2UT 的提升在 $p < 0.01$ 水平下统计显著

2.3.2　主要结果

2.3.2.1　法语到英语翻译结果

表2-1展示了在 CVSS-C Fr→En 和 CVSS-T Fr→En 数据集上的实验结果。可以得到以下发现：

（1）与之前的自回归模型相比，DASpeech 在翻译质量上明显超越一阶段模型 S2UT 和 Translatotron，在 CVSS-C 上分别取得了 2.80 和 8.07 的 ASR-BLEU 提升，并与二阶段模型 Translatotron 2 的性能持平甚至更优，在 CVSS-T 上超出 0.87 个 ASR-BLEU。在解码速度方面，DASpeech 相较于 S2UT 取得了最高 18.53

倍的加速。

（2）DASpeech 无需知识蒸馏和迭代解码，在翻译质量上以显著优势超越先前的非自回归模型 TranSpeech，ASR-BLEU 提升达 5.98 分，同时在解码速度上也更快，加速比从 3.35 倍提升至 16.29 倍。

（3）DASpeech 性能明显优于相应的级联系统 DAT + FastSpeech 2，在 $\lambda = 0.5$ 的配置下 ASR-BLEU 高出 2.23 分，证明了本章提出的期望路径训练方法的有效性。同时观察到一个现象：级联系统在较大的图尺寸下（$\lambda = 1.0$）表现更好，而 DASpeech 在较小的图尺寸下（$\lambda = 0.5$）效果更优。原因在于较大的图尺寸虽然能提升语音到文本翻译的性能，但同时也给端到端训练带来了更大的挑战。

（4）在包含多说话人目标语音的 CVSS-T 数据集上，Translatotron 和 Translatotron 2 因目标梅尔谱更难预测而出现性能下降，如 Translatotron 的 ASR-BLEU 从 16.96 降至 11.25。相比之下，DASpeech 的声学解码器通过显式引入音高、能量等变化信息来缓解声学多峰性问题，因此在 CVSS-T 上的性能依然出色，在 Joint-Viterbi 解码下达到 25.26 的 ASR-BLEU，甚至优于 CVSS-C 上的结果。

2.3.2.2 多语言翻译结果

表 2-2 CVSS-C 多语言数据集上的语音翻译结果

Table 2-2 Speech translation results on CVSS-C multilingual datasets

模型		ASR-BLEU (X→En)				加速比
		平均	高资源	中资源	低资源	
S2UT[1]		5.15	16.74	6.24	0.84	/
UnitY[3]		8.15	24.97	9.78	1.86	1.01×
Translatotron 2[4]		**8.74**	**25.92**	**11.07**	**2.04**	1.00×
DASpeech	+ Lookahead	7.42	22.84	9.51	1.41	**12.96**×
($\lambda = 0.5$)	+ Joint-Viterbi	7.43	22.80	9.49	1.45	10.99×

本章还在 CVSS-C 数据集上训练了从多种源语言翻译到英语的统一 S2ST 模型，结果如表2-2所示。表中报告了所有语言的平均 ASR-BLEU 分数以及高、中、低资源语言的平均分数。结果表明，DASpeech 在多语言环境下仍然明显优于 S2UT，但与 Translatotron 2 和 UnitY 相比性能略有差距，平均 ASR-BLEU 落后 Translatotron 2 约 1.3 分。然而，DASpeech 的解码速度是 Translatotron 2 的约 13 倍，在翻译质量与解码速度之间实现了更好的权衡。

2.3.3 分析实验

2.3.3.1 期望路径训练与最优路径训练的比较

表2-3展示了期望路径训练和最优路径训练在 CVSS-C Fr→En 测试集上的对比结果。在所有配置下，期望路径训练均优于最优路径训练，提升幅度为 0.19

表 2-3　期望路径训练与最优路径训练的对比

Table 2-3　Comparison of expect-path training and best-path training

模型		最优路径	期望路径	Δ
DASpeech	+ Lookahead	24.45	24.71	+0.26
($\lambda = 0.5$)	+ Joint-Viterbi	24.84	25.03	+0.19
DASpeech	+ Lookahead	24.18	24.41	+0.23
($\lambda = 1.0$)	+ Joint-Viterbi	24.46	24.80	+0.34

至 0.34 个 ASR-BLEU。这一结果验证了本章的分析：最优路径训练仅让最优路径上的隐状态参与 TTS 训练，可能导致其余隐状态训练不充分；而期望路径训练让所有隐状态都参与 TTS 训练，充分利用了 DAG 中的信息，从而取得了更好的性能。两种训练方法的时间复杂度均为 $\mathcal{O}(ML^2)$。

2.3.3.2　解码速度分析

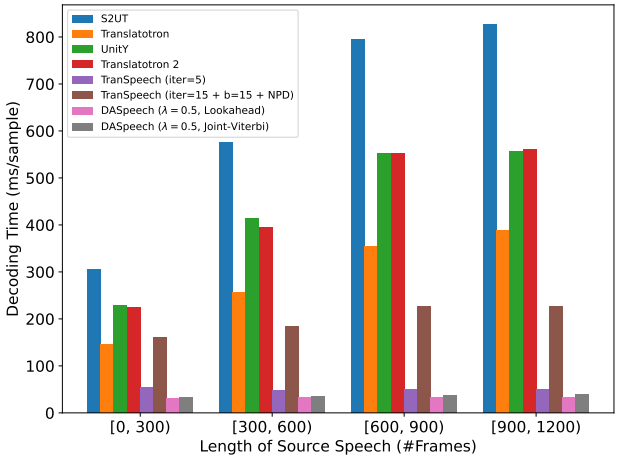

图 2-2　不同源语音长度下的翻译延迟对比

Figure 2-2　Translation latency across different source speech lengths

不同语音长度下的解码延迟　图2-2展示了不同模型针对不同长度源语音的翻译延迟。结果表明，自回归模型（S2UT、Translatotron、UnitY 和 Translatotron 2）的翻译延迟随源语音长度的增加而显著增长。相比之下，非自回归模型（TranSpeech 和 DASpeech）的翻译延迟几乎不受源语音长度的影响。在翻译较长的语音输入时，DASpeech 的解码速度可以达到 S2UT 的 20 倍以上。

翻译质量与解码速度的权衡　图2-3展示了不同模型的质量-速度权衡。通过调整超参数 λ，可以改变 DASpeech 的翻译质量和解码延迟。具体来说，随着 λ 的增加，模型的解码延迟会增大，而在 $\lambda = 0.5$ 时翻译质量达到最佳。从图中可以看出，DASpeech 在所有模型中实现了翻译质量和解码延迟之间的最佳权衡。

批量解码下的加速效果　在批量解码场景下，非自回归模型的加速优势可能减弱。本章在不同批量大小下测试了 DASpeech 的解码加速比，结果如图2-4所

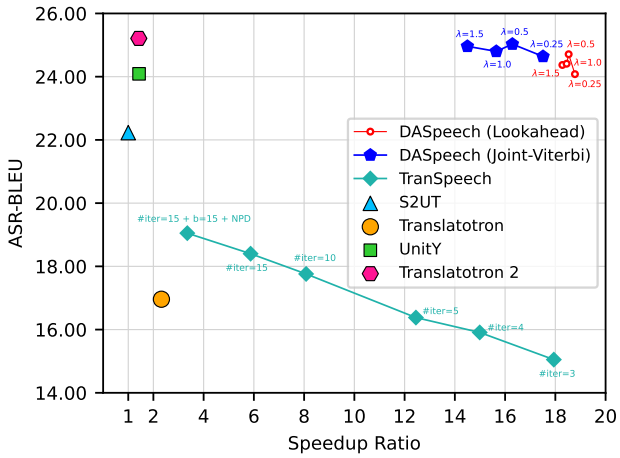

图 2-3　翻译质量与解码速度的权衡

Figure 2-3　Trade-off between translation quality and decoding speed

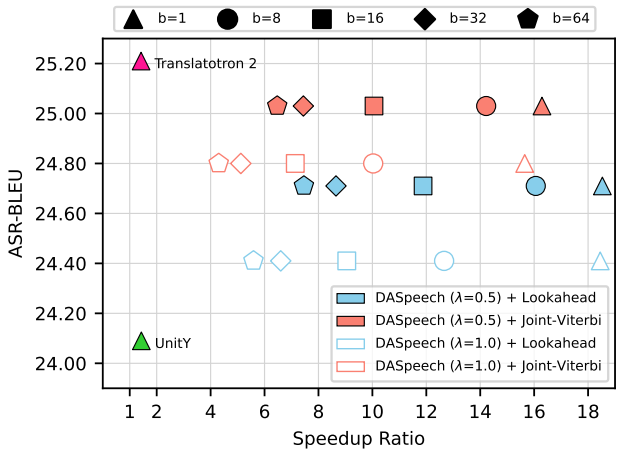

图 2-4　不同批量大小下的解码加速比与翻译质量

Figure 2-4　Speedup ratio and ASR-BLEU with different batch decoding sizes

示。随着批量大小的增加，加速比逐步降低，但 DASpeech（$\lambda = 0.5$, Joint-Viterbi）在批量大小为 64 时仍可达到 6 倍以上的加速，且翻译质量与 Translatotron 2 持平。

2.3.3.3　图尺寸的影响

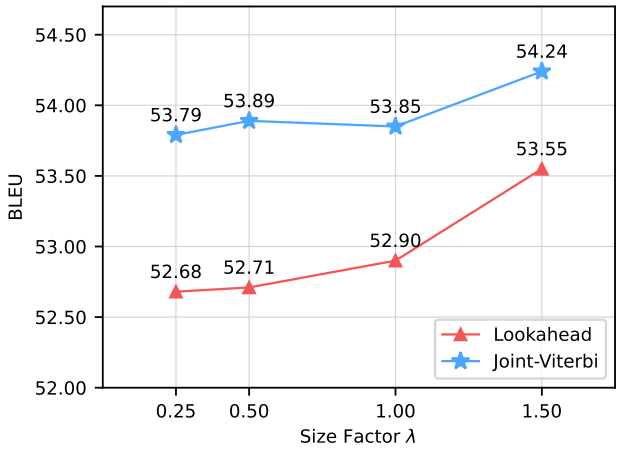

图 2-5　不同图尺寸下 S2TT 模型的翻译质量

Figure 2-5　S2TT translation quality under different graph sizes

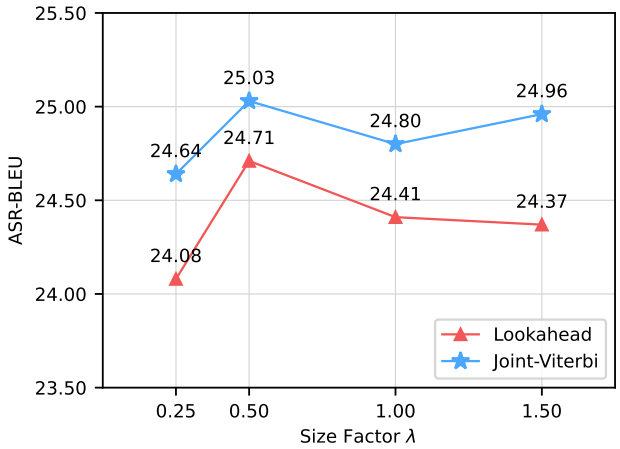

图 2-6　不同图尺寸下 DASpeech 的翻译质量

Figure 2-6　DASpeech translation quality under different graph sizes

DAG 的图尺寸由超参数 λ 控制，即 $L = \lambda \cdot N$。本章在 λ 取 0.25 至 1.5 的范围内研究了图尺寸对性能的影响，结果如图2-5和图2-6所示。对于 S2TT DA-Transformer 模型，其翻译性能随图尺寸的增大而持续提升，这与机器翻译中的观察一致。然而，DASpeech 在 $\lambda = 0.5$ 时取得最佳性能，更大的图尺寸反而导致性能下降。原因在于较大的图尺寸增加了端到端训练的难度，影响了语言解码器与声学解码器之间的协同优化。

表 2-4 各模型的说话人相似度对比

Table 2-4 Comparison of speaker similarity across models

模型		说话人相似度
真实语音		0.48
基于离散单元的 S2ST 模型		
S2UT[1]		0.03
UnitY[3]		0.03
TranSpeech[5]		0.03
基于梅尔谱的 S2ST 模型		
Translatotron[2]		0.04
Translatotron 2[4]		0.05
DASpeech	+ Lookahead	**0.14**
($\lambda = 0.5$)	+ Joint-Viterbi	0.10

2.3.3.4 音色保持能力分析

本章在 CVSS-T Fr→En 数据集上研究了各模型的音色保持能力。CVSS-T 中目标语音的音色来自对应的源语音说话人。表2-4展示了各模型翻译结果的平均说话人相似度。可以发现：（1）基于离散单元的 S2ST 模型，如 S2UT、UnitY 和 TranSpeech，由于离散单元中包含的说话人信息很少，几乎无法保持源说话人的音色，说话人相似度仅约 0.03；（2）DASpeech 的说话人相似度达到 0.14，明显优于 Translatotron 的 0.04 和 Translatotron 2 的 0.05，这是因为其声学解码器通过显式引入目标语音的变化信息，能够学习更复杂的目标分布，从而自发地展现出一定的音色保持能力。

2.4 本章小结

本章围绕语音到语音翻译任务中翻译质量与解码效率的矛盾，针对非自回归框架下如何有效建模目标语音的多峰分布这一关键问题，提出了 DASpeech——一个非自回归的二阶段端到端语音到语音翻译模型。DASpeech 通过有向无环图 Transformer 建模语言多样性、通过 FastSpeech 2 建模声学多样性，并提出了期望路径训练算法实现端到端训练。

在 CVSS 法语到英语数据集上的实验结果表明，DASpeech 在翻译质量上与 Translatotron 2 相当甚至更优，同时解码速度提升最高达 18.53 倍；相比先前的非自回归模型 TranSpeech，DASpeech 在翻译质量和解码速度上均取得了显著优势。分析实验进一步验证了期望路径训练优于最优路径训练、DASpeech 在复杂声学条件下的鲁棒性以及其自发涌现的音色保持能力。

DASpeech 的主要不足在于：其语言解码器和声学解码器需要共享音素词表，

这限制了各自选用最优的预训练模型。此外，DASpeech 的训练依赖于平行语音数据，而这类数据在实际中较为稀缺。这些问题将在下一章的工作中得到解决。

第 3 章　ComSpeech

第 4 章　LLaMA-Omni

第 5 章　LLaMA-Omni 2

第 6 章　总结与展望

参考文献

[1] Lee A, Chen P J, Wang C, et al. Direct speech-to-speech translation with discrete units [C/OL]// Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Dublin, Ireland: Association for Computational Linguistics, 2022: 3327-3339. https://aclanthology.org/2022.acl-long.235. DOI: 10.18653/v1/2022.acl-long.235.

[2] Jia Y, Weiss R J, Biadsy F, et al. Direct speech-to-speech translation with a sequence-to-sequence model [C/OL]//Kubin G, Kacic Z. Interspeech 2019, 20th Annual Conference of the International Speech Communication Association, Graz, Austria, 15-19 September 2019. ISCA, 2019: 1123-1127. https://doi.org/10.21437/Interspeech.2019-1951.

[3] Inaguma H, Popuri S, Kulikov I, et al. UnitY: Two-pass direct speech-to-speech translation with discrete units [C/OL]//Rogers A, Boyd-Graber J, Okazaki N. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Toronto, Canada: Association for Computational Linguistics, 2023: 15655-15680. https://aclanthology.org/2023.acl-long.872. DOI: 10.18653/v1/2023.acl-long.872.

[4] Jia Y, Ramanovich M T, Remez T, et al. Translatotron 2: High-quality direct speech-to-speech translation with voice preservation [C/OL]//Chaudhuri K, Jegelka S, Song L, et al. Proceedings of Machine Learning Research: volume 162 Proceedings of the 39th International Conference on Machine Learning. PMLR, 2022: 10120-10134. https://proceedings.mlr.press/v162/jia22b.html.

[5] Huang R, Liu J, Liu H, et al. Transpeech: Speech-to-speech translation with bilateral perturbation [C/OL]//The Eleventh International Conference on Learning Representations. 2023. https://openreview.net/forum?id=UVAmFAtC5ye.

[6] Zhu Y, Gao Z, Zhou X, et al. DiffS2UT: A semantic preserving diffusion model for textless direct speech-to-speech translation [C/OL]//Bouamor H, Pino J, Bali K. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 11573-11583. https://aclanthology.org/2023.emnlp-main.709. DOI: 10.18653/v1/2023.emnlp-main.709.

[7] Gu J, Bradbury J, Xiong C, et al. Non-autoregressive neural machine translation [C/OL]//6th International Conference on Learning Representations, ICLR 2018, Vancouver, BC, Canada, April 30 - May 3, 2018, Conference Track Proceedings. OpenReview.net, 2018. https://openreview.net/forum?id=B1l8BtlCb.

[8] Huang F, Zhou H, Liu Y, et al. Directed acyclic transformer for non-autoregressive machine translation [C]//Proceedings of the 39th International Conference on Machine Learning, ICML 2022. 2022.

[9] Ren Y, Hu C, Tan X, et al. Fastspeech 2: Fast and high-quality end-to-end text to speech [C/OL]//International Conference on Learning Representations. 2021. https://openreview.net/forum?id=piLPYqxtWuA.

[10] Huang F, Ke P, Huang M. Directed acyclic transformer pre-training for high-quality non-autoregressive text generation [J]. Transactions of the Association for Computational Linguistics, 2023.

[11] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [C/OL]//Guyon I, Luxburg U V, Bengio S, et al. Advances in Neural Information Processing Systems: volume 30. Curran Associates, Inc., 2017. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.

[12] Gulati A, Qin J, Chiu C C, et al. Conformer: Convolution-augmented Transformer for Speech Recognition [C/OL]//Proc. Interspeech 2020. 2020: 5036-5040. DOI: 10.21437/Interspeech.2020-3015.

[13] Dai Z, Yang Z, Yang Y, et al. Transformer-XL: Attentive language models beyond a fixed-length context [C/OL]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy: Association for Computational Linguistics, 2019: 2978-2988. https://aclanthology.org/P19-1285. DOI: 10.18653/v1/P19-1285.

[14] Rabiner L. A tutorial on hidden markov models and selected applications in speech recognition [J/OL]. Proceedings of the IEEE, 1989, 77(2): 257-286. DOI: 10.1109/5.18626.

[15] Viterbi A. Error bounds for convolutional codes and an asymptotically optimum decoding algorithm [J/OL]. IEEE Transactions on Information Theory, 1967, 13(2): 260-269. DOI: 10.1109/TIT.1967.1054010.

[16] Qian L, Zhou H, Bao Y, et al. Glancing transformer for non-autoregressive neural machine translation [C/OL]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 1993-2003. https://aclanthology.org/2021.acl-long.155. DOI: 10.18653/v1/2021.acl-long.155.

[17] Kong J, Kim J, Bae J. Hifi-gan: Generative adversarial networks for efficient and high fidelity speech synthesis [C/OL]//Larochelle H, Ranzato M, Hadsell R, et al. Advances in Neural Information Processing Systems: volume 33. Curran Associates, Inc., 2020: 17022-17033. https://proceedings.neurips.cc/paper_files/paper/2020/file/c5d736809766d46260d816d8dbc9eb44-Paper.pdf.

[18] Shao C, Ma Z, Feng Y. Viterbi decoding of directed acyclic transformer for non-autoregressive machine translation [C]//Findings of EMNLP 2022. 2022.

[19] Jia Y, Tadmor Ramanovich M, Wang Q, et al. CVSS corpus and massively multilingual speech-to-speech translation [C]//Proceedings of Language Resources and Evaluation Conference (LREC). 2022: 6691-6703.

[20] Wang C, Wu A, Pino J. Covost 2: A massively multilingual speech-to-text translation corpus [Z]. 2020.

[21] Veaux C, Yamagishi J, MacDonald K. Cstr vctk corpus: English multi-speaker corpus for cstr voice cloning toolkit [C]//2017.

[22] Kingma D P, Ba J. Adam: A method for stochastic optimization [C/OL]//Bengio Y, LeCun Y. 3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings. 2015. http://arxiv.org/abs/1412.6980.

[23] Ott M, Edunov S, Baevski A, et al. fairseq: A fast, extensible toolkit for sequence modeling [C]//Proceedings of NAACL-HLT 2019: Demonstrations. 2019.

[24] Post M. A call for clarity in reporting BLEU scores [C/OL]//Proceedings of the Third Conference on Machine Translation: Research Papers. Brussels, Belgium: Association for Computational Linguistics, 2018: 186-191. https://www.aclweb.org/anthology/W18-6319. DOI: 10.18653/v1/W18-6319.

[25] Papineni K, Roukos S, Ward T, et al. Bleu: a method for automatic evaluation of machine translation [C/OL]//Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics. Philadelphia, Pennsylvania, USA: Association for Computational Linguistics, 2002: 311-318. https://www.aclweb.org/anthology/P02-1040. DOI: 10.3115/1073083.1073135.

[26] Wan L, Wang Q, Papir A, et al. Generalized end-to-end loss for speaker verification [C/OL]// 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Calgary, AB, Canada: IEEE Press, 2018: 4879–4883. https://doi.org/10.1109/ICASSP.2018.8462665.

[27] Inaguma H, Popuri S, Kulikov I, et al. UnitY: Two-pass direct speech-to-speech translation with discrete units [C/OL]//Rogers A, Boyd-Graber J, Okazaki N. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Toronto, Canada: Association for Computational Linguistics, 2023: 15655-15680. https://aclanthology.org/2023.acl-long.872. DOI: 10.18653/v1/2023.acl-long.872.

致 谢

2026 年 6 月

作者简历及攻读学位期间发表的学术论文与其他相关学术成果

作者简历：

已发表（或正式接受）的学术论文：

(1)

参加的研究项目及获奖情况：